

问题一 Y 染色体浓度影响因素分析与关系模型

1 问题分析

问题一要求分析胎儿 Y 染色体浓度与孕周、孕妇 BMI 等因素之间的关系，并建立相应的关系模型。附件数据并非简单的独立横截面数据：同一孕妇通常存在多个孕周的检测记录，部分同次采血样本还进行了重复测序。因此，本题的关键不仅是识别变量间的相关关系，还要正确处理孕妇内重复测量和同次采血重复测序所造成的相关性。基于此，本文按照“数据结构识别 - 探索性分析 - 模型选择 - 参数估计 - 诊断与稳健性检验”的思路建立关系模型。

2 数据预处理与结构识别

男胎检测数据共有 1082 条记录，涉及 267 名孕妇，其中 260 名孕妇具有至少两个不同孕周的有效观测，表明数据具有明显的纵向重复测量结构。检测孕周统一换算为连续周数：

$$t = w + d / 7$$

其中 w 为完整孕周数， d 为额外天数。Y 染色体浓度、BMI 和检测孕周均无缺失，且不存在完全重复记录。

进一步按照“孕妇代码 + 检测抽血次数”识别同次采血记录，共发现 40 个同次采血重复测序组。由于这些记录来源于同一生物学采样，若全部作为独立样本会造成伪重复。故主分析以一次采血为基本分析单位，对同次采血的 Y 染色体浓度取均值，得到 1021 个采血层面的观测；原始 1082 条记录保留用于敏感性分析。

3 探索性数据分析

3.1 Y 染色体浓度与检测孕周

Y 染色体浓度与检测孕周的 Pearson 相关系数为 0.1266，Spearman 相关系数为 0.0843，边际上呈弱正相关。图 1 中线性拟合与 LOWESS 平滑曲线存在可见差异，提示孕周效应不能仅由简单线性关系充分描述。




图 1 Y 染色体浓度与检测孕周的关系

3.2 Y 染色体浓度与 BMI

Y 染色体浓度与 BMI 的 Pearson 和 Spearman 相关系数分别为 -0.1513 和 -0.1550，总体呈负相关。图 2 显示线性拟合总体向下，LOWESS 曲线存在局部波动。由于边际平滑曲线会受到孕周分布、重复测量和样本稀疏区间影响，BMI 的最终效应方向和显著性仍以多变量混合效应模型为准。




图 2 Y 染色体浓度与 BMI 的关系

3.3 个体重复测量结构

图 3 连接同一孕妇在不同孕周的检测记录。不同孕妇的 Y 染色体浓度基础水平和随孕周变化的轨迹均存在明显差异，且同一孕妇内部观测并非相互独立。这一数据结构说明普通多元线性回归的独立性假设不适合作为主模型，需要引入孕妇层面的随机效应。




图 3 不同孕妇 Y 染色体浓度的个体纵向轨迹

4 线性混合效应模型

4.1 模型构建

针对重复测量结构，本文采用线性混合效应模型（Linear Mixed-Effects Model, LMM）。固定效应用于描述总体人群中孕周、BMI 和年龄与 Y 染色体浓度的关系；随机截距用于刻画不同孕妇的基础浓度差异，随机孕周斜率用于刻画不同孕妇随孕周变化速度的差异。

BMI、体重和身高之间存在确定性的数学关系，诊断中三者的方差膨胀因子均很高，因此不同时纳入模型。考虑到 BMI 是题目后续分析的核心因素，模型保留 BMI，并以年龄作为控制变量。

为降低孕周一次项和二次项之间的相关性，将孕周中心化：

$$W_{ij} = t_{ij} - \bar{t}$$

最终模型为：

$$Y_{ij} = \beta_0 + \beta_1 W_{ij} + \beta_2 W_{ij}^2 + \beta_3 BMI_{ij} + \beta_4 Age_i + b_{0i} + b_{1i} W_{ij} + \epsilon_{ij}$$

其中， Y_{ij} 为孕妇 i 第 j 次采血时的 Y 染色体浓度； β_0 至 β_4 为固定效应参数； b_{0i} 和 b_{1i} 分别为孕妇 i 的随机截距和随机孕周斜率； ϵ_{ij} 为随机误差。

4.2 参数估计与显著性

模型基于 1021 个采血观测和 267 名孕妇进行最大似然估计并成功收敛，对数似然为 2463.64，AIC 为 -4909.29，BIC 为 -4864.93。固定效应估计见表 1。

变量	估计系数	标准误	95% 置信区间	p 值
截距	0.138148	0.022057	[0.094917, 0.181379]	<0.001
中心化孕周 W	0.003176	0.000253	[0.002680, 0.003673]	<0.001
孕周二次项 W^2	0.000264	0.000034	[0.000197, 0.000331]	<0.001
BMI	-0.001486	0.000524	[-0.002512, -0.000459]	0.0046

变量	估计系数	标准误	95% 置信区间	p 值
年龄	-0.000515	0.000487	[-0.001469, 0.000440]	0.2908

表 1 LMM 固定效应参数估计

孕周一次项和二次项均达到统计显著水平，说明 Y 染色体浓度与孕周之间存在显著的非线性关系。为避免仅依据二次项符号推断全区间单调性，进一步结合观测区间内的模型预测曲线判断其实际变化趋势。BMI 系数为 -0.001486 ($p=0.0046$)，表明在控制孕周和年龄后，BMI 对 Y 染色体浓度具有显著负向影响：BMI 每增加 1 kg/m²，模型期望的 Y 染色体浓度平均下降约 0.001486，即约 0.149 个百分点。年龄 $p=0.2908$ ，当前数据不足以证明其存在显著的独立效应。

随机截距标准差为 0.03005，随机孕周斜率标准差为 0.00272，二者相关系数约为 0.485，进一步说明不同孕妇之间既存在基础水平差异，也存在孕周变化轨迹差异。

4.3 模型关系的可视化解释

图 4 给出了 BMI 第 25、50、75 百分位水平下的固定效应预测曲线。观测孕周范围内，三条预测曲线总体随孕周增加而上升，支持“Y 染色体浓度随孕周总体升高且存在非线性”的解释；同时，在相同孕周下，较高 BMI 对应较低的预测 Y 染色体浓度，与 BMI 的显著负系数一致。图中的 BMI 水平仅用于展示问题一模型效应，不作为问题二的最终 BMI 分组边界。




图 4 不同 BMI 代表水平下 Y 染色体浓度随孕周变化的模型预测

5 模型诊断与稳健性检验

5.1 残差诊断

残差-拟合值图中残差总体围绕 0 分布，未观察到明显的系统性曲线结构，但不同拟合值区域的离散程度并非完全一致；Q-Q 图中部与理论直线较为接近，而两端存在较明显偏离。因此，模型能够较好描述主要均值结构，但残差正态性在尾部并不完美，相关显著性结论应结合敏感性分析共同判断，而不宜表述为“完全满足正态假设”。




图 5 LMM 残差与拟合值关系




图 6 LMM 残差 Q-Q 图

5.2 重复测序与敏感性分析

同次采血重复测序组的 Y 染色体浓度极差中位数约为 0.00884，95% 分位数约为 0.01780，说明重复测序造成的数值波动在接近 4% 阈值时可能具有实际影响。因此，主分析对同次采血重复测序取均值，以避免伪重复；该误差结构将在后续阈值时点问题中进一步用于测量误差敏感性分析。




图7 同次采血重复测序的Y染色体浓度极差分布

进一步使用未经聚合的1082条原始记录重新拟合相同

LMM。结果中孕周一次项与二次项仍显著为正，BMI仍显著为负，年龄仍不显著，效应方向和显著性结论均与主分析一致。因此，问题一的核心结论并非由同次采血取均值这一处理方式所驱动，具有较好的处理稳健性。

6 问题一结论

综合重复测量结构、固定效应估计、模型预测及敏感性分析可知：Y

染色体浓度与检测孕周之间存在显著的非线性关系，在样本观测范围内总体随孕周增加而升高；BMI在控制孕周和年龄后仍表现出显著负向影响，即BMI较高的孕妇在相同孕周下通常具有较低的Y染色体浓度；年龄未表现出统计显著的独立效应。同时，不同孕妇的基础Y染色体浓度和随孕周变化的轨迹存在明显个体异质性，因此采用包含随机截距和随机孕周斜率的LMM是必要的。

由于男胎NIPT检测与Y染色体浓度达到4%阈值密切相关，而BMI已被证实对Y染色体浓度具有显著负向作用，故不同BMI水平孕妇达到4%阈值的时间可能存在系统差异。该结论为问题二进一步研究BMI分组、达标时间以及最佳NIPT检测时点提供了直接依据。