

问题一 Y 染色体浓度影响因素分析与关系模型

1 问题分析

问题一要求分析胎儿 Y 染色体浓度与孕妇孕周、BMI 等因素之间的关系，并建立相应的关系模型。数据中同一孕妇往往具有多个孕周的检测记录，且部分同次采血样本存在重复测序，因此观测值并非相互独立。若直接采用普通多元线性回归，会忽略同一孕妇内部观测的相关性，并可能使重复测序样本获得过高权重。基于此，本文首先对重复测量结构进行识别和处理，再通过探索性分析确定主要关系形态，最终建立包含孕妇个体随机效应的线性混合效应模型。

2 数据预处理与探索性分析

2.1 数据预处理

男胎检测数据共有 1082 条记录，涉及 267 名孕妇，其中 260 名孕妇具有至少两个不同孕周的有效观测，说明数据具有明显的纵向重复测量结构。检测孕周由“孕周+天数”统一转换为连续周数：

$$t = w + d / 7$$

其中， w 为完整孕周数， d 为额外天数。数据中 Y 染色体浓度、BMI 和检测孕周均无缺失，且不存在完全重复记录。

进一步按照“孕妇代码 + 检测抽血次数”识别同次采血的重复测序记录，共发现 40 个重复测序组。由于这些记录来源于同一次生物学采样，不宜视为相互独立的观测，因此本文以一次采血作为主分析单位，对同次采血的 Y 染色体浓度取均值，最终获得 1021 个采血层面的观测。原始未聚合数据保留用于后续敏感性分析。

2.2 Y 染色体浓度与孕周、BMI 的关系

对原始观测进行探索性分析。Y 染色体浓度与检测孕周的 Pearson 相关系数为 0.1266，Spearman 相关系数为 0.0843，整体呈正相关；Y 染色体浓度与 BMI 的 Pearson 和 Spearman 相关系数分别为 -0.1513 和 -0.1550，整体呈负相关。进一步的平滑趋势诊断显示，Y 染色体浓度与孕周之间存在一定的非线性特征，因此在后续模型中考虑孕周的二次效应。




图 1 Y 染色体浓度与检测孕周、BMI 的关系

3 线性混合效应模型的建立

3.1 模型选择

由于同一孕妇具有多次检测记录，其个体内观测存在相关性，普通线性回归的独立性假设难以满足。为同时刻画总体影响规律与孕妇个体差异，本文采用线性混合效应模型（Linear Mixed-Effects Model, LMM）。其中设置孕妇层面的随机截距，以描述不同孕妇 Y 染色体浓度基础水平的差异；同时设置孕周随机斜率，以描述不同孕妇 Y 染色体浓度随孕周变化速度的差异。

BMI、体重和身高之间满足 $BMI = Weight / Height^2$ ，三者存在显著共线性。诊断结果显示 BMI、体重和身高的方差膨胀因子分别约为 218.60、351.34 和 106.90，因此不将三者同时纳入模型。考虑到 BMI 是题目后续分组和最佳检测时点分析的核心变量，模型保留 BMI，并将年龄作为控制变量。

3.2 模型表达式

为降低孕周一次项与二次项之间的相关性，首先对检测孕周进行中心化：

$$W_{ij} = t_{ij} - \bar{t}$$

其中， t_{ij} 表示孕妇 i 第 j 次采血时的检测孕周， $\bar{t}$ 为全部采血观测的平均孕周。最终模型表示为：

$$Y_{ij} = \beta_0 + \beta_1 W_{ij} + \beta_2 W_{ij}^2 + \beta_3 BMI_{ij} + \beta_4 Age_i + b_{0i} + b_{1i} W_{ij} + \epsilon_{ij}$$

其中， Y_{ij} 为 Y 染色体浓度； β_0 至 β_4 为固定效应参数； b_{0i} 为孕妇 i 的随机截距； b_{1i} 为孕妇 i 的随机孕周斜率； ϵ_{ij} 为随机误差。假设随机效应服从均值为零的二维正态分布，随机误差服从均值为零、方差为 σ^2 的正态分布。

4 模型结果与分析

4.1 固定效应分析

模型基于 1021 个采血观测和 267 名孕妇进行最大似然估计，并成功收敛。模型对数似然为 2463.64，AIC 为 -4909.29，BIC 为 -4864.93。固定效应参数估计结果如表 1 所示。

变量	估计系数	标准误	95% 置信区间	p 值
截距	0.138148	0.022057	[0.094917, 0.181379]	<0.001
中心化孕周 W	0.003176	0.000253	[0.002680, 0.003673]	<0.001
孕周二次项 W^2	0.000264	0.000034	[0.000197, 0.000331]	<0.001
BMI	-0.001486	0.000524	[-0.002512, -0.000459]	0.0046
年龄	-0.000515	0.000487	[-0.001469, 0.000440]	0.2908

表 1 线性混合效应模型固定效应估计结果

孕周一次项和二次项的估计系数分别为 0.003176 和 0.000264，且均在 0.001 水平下显著，说明在样本观测范围内，Y 染色体浓度总体随孕周增加而上升，并具有显著的非线性变化特征。

BMI 的估计系数为 -0.001486， $p=0.0046$ ，在控制孕周及年龄后仍具有显著负向效应。在其他条件保持不变时，BMI 每增加 1 kg/m²，模型期望的 Y 染色体浓度平均下降约 0.001486，即约 0.149 个百分点。因此，BMI 较高的孕妇在相同孕周下通常具有较低的 Y 染色体浓度。

年龄的估计系数为 -0.000515, $p=0.2908$, 未达到 0.05 的显著性水平。因此, 在控制孕周和 BMI 后, 当前数据尚不足以证明年龄对 Y 染色体浓度存在显著的独立影响。

4.2 个体差异分析

模型估计的随机截距标准差为 0.03005, 随机孕周斜率标准差为 0.00272, 随机截距与随机斜率的相关系数约为 0.485。这表明不同孕妇之间不仅存在 Y 染色体浓度基础水平的差异, 其随孕周变化的速度也存在明显个体异质性, 从而进一步说明在模型中引入孕妇层面的随机效应是必要的。




图 2 不同 BMI 代表水平下 Y 染色体浓度随孕周变化的模型预测曲线

由图 2 可见, 在所考察的 BMI 代表水平下, Y 染色体浓度总体随孕周增加而提高; 在相同孕周附近, 较高 BMI 对应的模型预测浓度整体较低, 与固定效应估计所得的 BMI 负向作用一致。图中不同 BMI 水平仅用于展示问题一中的模型关系, 不作为后续问题的最终 BMI 分组边界。

5 模型诊断与稳健性检验

为检验模型假设, 对模型残差进行诊断。残差与拟合值之间未表现出明显的系统性曲线结构, 残差 Q-Q 图仅在尾部存在轻微偏离, 整体未发现严重的模型假设违背。




图3 线性混合效应模型残差诊断

此外，为检验同次采血重复测序聚合方式是否影响主要结论，本文使用未经聚合的 1082 条原始记录重新拟合相同的混合效应模型。敏感性分析结果显示，孕周一次项和二次项仍显著为正，BMI 仍显著为负，年龄仍未达到统计显著水平，各变量的效应方向与显著性结论均保持一致。由此说明，问题一的主要结论对重复测序数据处理方式具有较好的稳健性。

6 问题一结论

通过对男胎 NIPT 检测数据的重复测量结构进行识别，并建立包含随机截距和随机孕周斜率的线性混合效应模型，可以得到以下结论：检测孕周与 Y 染色体浓度之间存在显著的正向且非线性的关系；孕妇 BMI 对 Y 染色体浓度具有显著负向影响；在控制孕周和 BMI 后，年龄尚未表现出显著的独立影响。同时，不同孕妇的 Y 染色体浓度基础水平及其随孕周变化的轨迹均存在明显个体差异。

上述结果表明，孕周和 BMI 是解释男胎 Y 染色体浓度变化的重要因素。由于男胎 NIPT 检测的可靠性与 Y 染色体浓度是否达到 4% 阈值密切相关，而 BMI 对 Y 染色体浓度具有显著负向作用，因此不同 BMI 水平孕妇达到 4% 阈值的时间可能存在系统差异。这为问题二进一步研究 BMI 分组、Y 染色体浓度达标时间以及最佳 NIPT 检测时点提供了模型基础。