

NIPT 的时点选择与胎儿的异常判定

摘 要

本文针对 NIPT 检测时点选择与胎儿异常判定问题，基于男胎和女胎的纵向检测数据开展建模分析。当前已完成问题背景、问题要求、问题分析以及问题二的建模与结果整理，其余问题完成后再统一补充摘要中的方法、关键结果和模型评价。

关键词：无创产前检测；Logistic 回归；CART 分组；敏感性分析

1 问题重述

1.1 问题背景

无创产前检测 (Non-invasive Prenatal Test, NIPT) 是一种通过采集孕妇血液并分析其中胎儿游离 DNA 片段, 对胎儿染色体异常风险进行评估的产前检测技术。与传统侵入性产前诊断方式相比, NIPT 具有安全性较高、检测过程方便等特点, 在唐氏综合征、爱德华氏综合征和帕陶氏综合征等常见染色体异常的早期筛查中具有重要作用。

NIPT 检测结果的可靠性受到孕周、孕妇身体质量指数以及测序质量等多种因素影响。对于男胎, 当 Y 染色体浓度达到一定水平时, 检测结果才具有较高的可信度。若检测时间过早, 胎儿游离 DNA 浓度可能不足, 从而增加检测失败或结果不稳定的可能; 若检测时间过晚, 又可能缩短发现异常后的临床处理时间。因此, 如何在检测可靠性与早期发现风险之间取得平衡, 是 NIPT 时点选择中的重要问题。

此外, 不同孕妇在年龄、身高、体重、BMI 和妊娠状况等方面存在个体差异, 采用统一的检测时间难以适用于所有人群。对于不携带 Y 染色体的女胎, 还需要结合染色体 Z 值、GC 含量和读段质量等信息建立异常判定方法。基于上述背景, 本文利用给定的男胎与女胎 NIPT 检测数据, 研究男胎检测时点的合理选择, 并建立女胎染色体异常判定模型。

1.2 问题要求

针对附件所给出的男胎与女胎 NIPT 检测数据, 本文需要完成以下四项任务:

问题一: 分析男胎 Y 染色体浓度与孕妇检测孕周、BMI 及其他相关指标之间的关系, 建立相应的关系模型, 并检验模型及相关变量的显著性。

问题二: 在 BMI 是影响男胎 Y 染色体浓度最早达标时间主要因素的条件下, 对男胎孕妇进行合理的 BMI 分组, 给出各组 BMI 区间和最佳 NIPT 检测时点, 使潜在风险尽量降低, 并分析检测误差的影响。

问题三: 在问题二基础上, 进一步考虑年龄、身高、体重等个体因素, 以及检测误差和 Y 染色体浓度达标比例的影响, 重新确定合理的 BMI 分组和各组最佳 NIPT 检测时点。

问题四: 针对女胎不携带 Y 染色体的特点, 以附件 AB 列中的 13、18、21 号染色体非整倍体结果作为异常判定依据, 综合考虑染色体 Z 值、GC 含量、测序读段指标、相关比例、X 染色体浓度和 BMI 等因素, 建立女胎异常判定方法。

2 问题分析

2.1 问题一分析

问题一研究男胎 Y 染色体浓度与检测孕周、BMI 及其他指标之间的数量关系, 是后续确定最佳检测时点的基础。首先统一孕周表示方式并进行描述性统计和可视化, 再建立 Y 染色体浓度与各影响因素之间的关系模型, 通过参数显著性、拟合优度和残差分析评价模型。由于同一孕妇可能存在多次检测记录, 还需处理个体内相关性, 预期得到孕周、BMI 等因素的影响方向、影响程度及统计显著性。

2.2 问题二分析

问题二承接问题一，将研究目标由“解释 Y 染色体浓度的变化”转化为“确定不同 BMI 人群的最佳 NIPT 检测时点”。利用问题一中孕周、BMI 与 Y 染色体浓度之间的关系，将 Y 染色体浓度达到或超过 4% 定义为达标，估计不同 BMI 和孕周下的达标概率。在此基础上对 BMI 进行数据驱动分组，并在检测可靠性与延迟发现风险之间进行权衡，为每组选择尽可能早且可靠的检测时点。最后通过重复测序、Bootstrap 和误差扰动分析结论的稳定性。

2.3 问题三分析

问题三是对问题二的扩展。问题二主要依据 BMI 进行群体分组，但实际达标时间还可能受到年龄、身高、体重、妊娠方式和测序质量的影响。因此需在保留 BMI 分组这一实际应用形式的同时，建立多因素达标概率模型，将更多个体特征纳入组内风险计算，重新确定各组最佳检测时点，并检验误差条件下分组边界和推荐时点的稳定性。

2.4 问题四分析

问题四的研究对象由男胎转为女胎。本文将附件 AB 列为空定义为无异常，出现 T13、T18、T21 或其组合定义为异常；以各染色体 Z 值、X 染色体浓度、GC 含量、测序读段指标、BMI 和孕周等作为候选特征建立分类模型。训练集和测试集按孕妇代码划分，避免重复记录造成信息泄漏，并使用召回率、特异度、F1 值和 ROC-AUC 等指标评价女胎异常判定效果。

3 模型假设

1. 假设附件中的检测记录及字段含义真实可靠，清洗过程中仅对同次采血的重复测序进行合并，不改变原始生物学观测。
2. 假设同次采血的 Y 染色体浓度测量误差相互独立、均值为零，且其方差在研究范围内近似稳定，以便利用重复测序差异估计测量误差。
3. 假设在 10 至 25 孕周的研究区间内，同一 BMI 水平下的群体达标概率不会随孕周增加而下降；观测中的局部波动主要由测量误差和个体差异造成。
4. 问题二以首次检测时 BMI 作为基线 BMI，并假设其能够代表孕妇所属的 BMI 群体，避免使用达标后的 BMI 造成时间信息倒置。
5. 假设样本所代表地区的检测流程在研究期内保持一致，模型结论主要用于相似高 BMI 人群的群体时点建议，不直接替代个体临床诊断。

4 数据预处理

4.1 重复检测记录的合并

男胎原始工作表包含 1082 条检测记录和 267 名孕妇。数据中既有同一孕妇的多次抽血，也有同次采血的重复测序。为避免将技术重复误认为独立生物样本，本文以“孕妇代码、检测日期、检测抽血次数”为联合键合并同次采血记录，对 Y 染色体浓度取中位数，并保留最小值、最大值、极差及是否跨越 4% 阈值等信息。共识别 19 组同次采血重复测序，合并后得到 1063 次独立采血记录。

表 1 问题二数据清洗统计

项目	数量
原始检测记录	1082 条
男胎孕妇	267 人
清洗后独立采血记录	1063 次
同次采血重复测序组	19 组
重复测序跨越 4% 阈值	4 组

4.2 变量标准化与达标状态构造

将 “ $aw + b$ ” 形式的孕周转换为连续周数：

$$W = a + \frac{b}{7}. \quad (1)$$

利用体重除以身高平方复核 BMI，差异均小于 0.02。为避免把达标之后发生的体重变化反向用于预测，问题二采用每名孕妇首次检测时的 BMI 作为基线 BMI。定义第 i 名孕妇第 j 次独立采血的达标状态为

$$D_{ij} = \mathbb{I}(Y_{ij} \geq 0.04), \quad (2)$$

其中 Y_{ij} 表示 Y 染色体浓度。GC 含量略低于 40% 的记录仅设置质量标记而不机械删除，避免一次性剔除大量临界样本。

4.3 删失结构说明

267 名孕妇中，217 人在第一次检测时已经达标，只能确定真实达标时间早于首次检测，属于左删失；43 人的真实达标时刻位于相邻两次检测之间，属于区间删失；7 人在最后一次检测时仍未达标，属于右删失。因此，首次观测到达标的孕周不能直接等同于精确的生理达标时间，后续模型应尽量使用全部纵向检测记录。

5 问题二的模型建立与求解

5.1 与问题一的联系及总体思路

问题一用于识别孕周、BMI 等指标与 Y 染色体浓度之间的关系；问题二进一步把这种关系转化为可执行的检测决策。其核心不再只是解释 Y 染色体浓度如何变化，而是回答 “不同 BMI 孕妇在何时检测，既能保证足够的达标概率，又能尽量避免延迟发现风险”。

为此，本文采用 “纵向达标概率建模—可靠性约束下的时点反演—CART 自动分组—误差与稳定性检验” 的四步框架。首先利用全部 1063 次独立采血记录建立达标概率模型；随后反演不同 BMI 水平达到目标可靠性的最早孕周；再利用一维 CART 将连续 BMI 压缩为若干可解释区间；最后使用 Bootstrap 和重复测序误差扰动检验结果稳定性。

5.2 首次观测达标孕周的探索性分析

先对 260 名曾观测到 Y 染色体浓度达标的孕妇，绘制基线 BMI 与首次观测达标孕周 T 的散点图，结果见图 1。Spearman 秩相关系数为 $\rho = 0.0878$ ，双侧检验 $p = 0.158$ ，表明二者仅呈极弱且不显著的正相关。




图 1 基线 BMI 与首次观测 Y 染色体浓度达标孕周

上述弱相关不能直接解释为 BMI 没有作用。由第 2 式可知，达标时间的观测依赖于实际采样安排；特别是首次检测已经达标的 217 名孕妇，其真实达标时刻只能确定为早于首次检测。若直接对首次观测达标孕周进行普通回归或 CART 分组，会把“何时接受检测”与“何时生理达标”混为一谈。因此，本文不把图 1 中的 T 作为主模型的连续响应变量，而改用每名孕妇的全部纵向检测记录建立达标概率模型。

5.3 纵向达标概率模型

5.3.1 模型设定

设 W_{ij} 为第 i 名孕妇第 j 次独立采血时的孕周， B_i 为其基线 BMI， D_{ij} 为第 2 式定义的达标状态。记

$$p_{ij} = P(D_{ij} = 1 \mid W_{ij}, B_i). \quad (3)$$

候选模型包括线性 Logistic 回归、含二次项与交互项的 Logistic 回归、样条 Logistic 回归和梯度提升树，并设置仅使用总体达标率的常数模型作为基准。线性 Logistic 模型写为

$$\text{logit}(p_{ij}) = \beta_0 + \beta_1 W_{ij} + \beta_2 B_i. \quad (4)$$

由于各孕妇的检测次数不同，若给每条记录相同权重，检测次数较多的孕妇会对参数估计产生过大影响。因此，将第 i 名孕妇全部记录的总权重设为 1，每条记录权重取其检测次数的倒数。

5.3.2 分组交叉验证与模型选择

为防止同一孕妇的多次记录同时出现在训练集和验证集中，采用以孕妇代码为分组单位的五折交叉验证。模型选择以 LogLoss 为主要指标，Brier 得分和 AUC 为辅助指标；LogLoss 和 Brier 越小，说明概率预测越准确，AUC 越大，说明区分达标与未达标记录的能力越强。相关方法可参考 Logistic 回归与统计学习理论 [1, 2]。

表 2 候选达标概率模型的分组五折交叉验证结果

模型	LogLoss	标准误	Brier	AUC
二次交互 Logistic	0.3853	0.0273	0.1127	0.5798
线性 Logistic	0.3866	0.0273	0.1130	0.5804
基准常数模型	0.3912	0.0242	0.1147	0.5000
样条 Logistic	0.3920	0.0320	0.1144	0.5705
梯度提升树	0.3992	0.0349	0.1156	0.6061




图 2 候选达标概率模型的交叉验证比较

由表 2 和图 2 可见，二次交互 Logistic 取得最低 LogLoss，但其与线性 Logistic 的差值仅为 0.0013，远小于相应交叉验证标准误 0.0273。依据一标准误差规则，在预测误差没有显著恶化的情况下优先选择结构更简单的线性 Logistic 模型。梯度提升树虽然 AUC 相对较高，但 LogLoss 和 Brier 均较差，说明其概率校准能力不足，不适合作为本题时点反演的主模型。

将线性 Logistic 模型系数换算回原始量纲, 得到

$$\text{logit}(p) = 5.3712 + 0.0412W - 0.1285B. \quad (5)$$

孕周系数为正、BMI 系数为负, 表示在控制另一变量后, 孕周增加有利于 Y 染色体浓度达标, 而 BMI 升高会降低同一孕周下的达标概率。不过, 最终模型 AUC 仅为 0.5804, 说明只使用 BMI 和孕周时个体区分能力有限。因此, 本文将该模型用于群体检测时点决策, 不将其解释为高精度个体诊断模型。

5.4 可靠性约束下的最佳检测时点

题目要求同时兼顾检测准确性和尽早发现风险。本文采用词典序决策准则: 首先满足预设的达标可靠性, 在满足可靠性的可行孕周中选择最早时点。为符合群体达标概率一般不随孕周下降的规律, 对预测概率曲线施加累积最大值约束。定义给定 BMI 下达到 90% 预测达标概率的最早孕周为

$$t_{0.90}(B) = \min \{w : P(Y \geq 0.04 \mid B, w) \geq 0.90\}, \quad 10 \leq w \leq 25. \quad (6)$$

对第 g 个 BMI 组, 令 $\bar{p}_g(w)$ 为组内孕妇在孕周 w 的平均预测达标概率, 则推荐时点为

$$t_g^* = \min \{w : \bar{p}_g(w) \geq q_g\}. \quad (7)$$

通常取 $q_g = 0.90$ 。若某组在 25 周内仍不能达到 90%, 则将可行阈值降为 85%, 在达到该阈值的最早孕周先行检测, 并对未达标样本安排复测。该规则避免为了追求小幅准确率提升而把检测过度推迟至治疗窗口更加紧张的阶段。

5.5 基于 CART 的 BMI 自动分组

以基线 BMI 为输入、模型反演得到的 $t_{0.90}$ 为输出, 建立一维 CART 回归树 [3]。CART 通过选择 BMI 切点, 使各叶节点内预测达标时点的离差平方和最小:

$$\min_{G_1, \dots, G_K} \sum_{g=1}^K \sum_{i \in G_g} (t_i - \bar{t}_g)^2. \quad (8)$$

为保证分组具有基本样本量, 规定每个叶节点至少包含 22 名孕妇, 并比较 3 至 5 个叶节点的方案。相应五折交叉验证 MAE 分别为 1.246、0.798 和 0.660 周; 根据一标准误差规则, 5 组方案仍是唯一满足阈值的方案, 故最终选择 5 个 BMI 组。模型确定的切点为 28.71、29.47、31.03 和 32.09, 分组结果如图 3 所示。




图 3 CART 自动 BMI 分组与推荐 NIPT 时点

表 3 BMI 分组、推荐检测时点及预测可靠性

组别	BMI 区间	人数	推荐孕周	平均达标率	检测策略
1	$B < 28.71$	25	10.5	90.1%	满足 90% 约束
2	$28.71 \leq B < 29.47$	31	14.0	90.1%	满足 90% 约束
3	$29.47 \leq B < 31.03$	67	17.5	90.1%	满足 90% 约束
4	$31.03 \leq B < 32.09$	35	22.0	90.2%	满足 90% 约束
5	$B \geq 32.09$	109	21.0	85.2%	初检后安排复测

由表 3 可知，前四组均选择达到 90% 平均达标概率的最早时点。第五组在 25 周内仍无法达到 90%，因此按照第 7 式的备用规则，在 21.0 周达到 85% 时先进行初检，并对未达标者尽快复测。由此可见，第五组推荐时点早于第四组并非模型认为高 BMI 孕妇更早达标，而是两组采用了不同的可靠性约束；这种处理体现了对延迟风险的控制。

不同 BMI 组的达标概率曲线如图 4 所示。总体上，BMI 越高，同一孕周下的预测达标概率越低，达到 90% 可靠性所需的时间越晚。最高 BMI 组在 25 周内仍未达到 90% 水平，也说明对其采用“较早初检加复测”比单纯延迟更为合理。




图 4 不同 BMI 组的 Y 染色体浓度预测达标概率曲线

5.6 分组稳定性与检测误差分析

5.6.1 BMI 切点的 Bootstrap 稳定性

对 267 名孕妇进行 300 次 Bootstrap 有放回抽样，每次重新拟合 5 叶节点 CART 并记录切点，结果见表 4。

表 4 300 次 Bootstrap 下 BMI 切点的稳定性

切点	原始值	Bootstrap 中位数	95% 区间
1	28.71	28.77	[28.48, 29.51]
2	29.47	29.53	[29.29, 30.23]
3	31.03	30.98	[30.86, 31.07]
4	32.09	32.09	[31.95, 32.24]

第三、第四切点的区间较窄，稳定性相对较好；第一、第二切点存在一定漂移。由于前两组样本量仅为 25 和 31，表中保留两位小数主要用于模型复现，实际应用时更适合按照约 0.5 个 BMI 单位进行近似解释，不宜将切点视为绝对精确的临床边界。

5.6.2 Y 染色体浓度测量误差

对于 19 组同次采血重复测序，设两次测量差为 Δ 。若单次测量误差独立同分布且方差为 σ^2 ，则

$$\text{Var}(\Delta) = 2\sigma^2. \quad (9)$$

据此估计单次 Y 染色体浓度测量误差标准差为 $\sigma = 0.004711$ ，即 0.471 个百分点。随后对每条 Y 染色体浓度加入 $N(0, \sigma^2)$ 扰动，重复 200 次重新判断 4% 阈值、拟合概率模型并计算推荐时点。平均有 3.26% 的检测记录在扰动后跨越 4% 阈值。

表 5 200 次测量误差扰动下推荐时点的稳定性

组别	原始推荐孕周	扰动中位数	95% 扰动区间
1	10.5	12.0	[10.0, 17.0]
2	14.0	16.0	[10.5, 20.0]
3	17.5	19.5	[16.0, 23.5]
4	22.0	22.0	[10.0, 25.0]
5	21.0	21.5	[19.0, 25.0]




图 5 Y 染色体浓度检测误差对推荐时点的影响

由表 5 和图 5 可知，第五组推荐时点中位数为 21.5 周，与原方案方向较为一致；部分中间 BMI 组的扰动区间较宽，表明接近 4% 阈值的测量误差可能明显改变推荐时点。因此，表 3 给出的时点应理解为群体层面的基准建议，对于临界 BMI 或临界 Y 浓度样本，应结合复测进行个体化判断。

5.7 问题二结论与模型评价

本文最终将男胎孕妇划分为 $B < 28.71$ 、 $[28.71, 29.47)$ 、 $[29.47, 31.03)$ 、 $[31.03, 32.09)$ 和 $B \geq 32.09$ 五组，推荐初次 NIPT 检测时点依次为 10.5、14.0、17.5、22.0 和 21.0 周。其中，最高 BMI 组由于在 25 周内不能达到 90% 预测达标概率，采用 21.0 周达到 85% 后先行检测并安排复测的策略。

该方法利用全部纵向检测记录，避免把首次观测达标孕周误认为精确生理达标时间；按孕妇代码分组的交叉验证减少了数据泄漏；一标准误差规则、最小叶节点约束和 Bootstrap 共同限制模型复杂度；误差扰动进一步量化了 4% 阈值附近的不确定性。其局限在于样本以高 BMI 孕妇为主，低 BMI 组样本量较少，且最终 Logistic 模型 AUC 仅为 0.5804。因此，本问结果适合作为相似人群的群体检测时点参考，问题三还需加入年龄、身高、体重和测序质量等因素提高个体化能力。

参考文献

- [1] David W. Hosmer, Stanley Lemeshow, and Rodney X. Sturdivant. *Applied Logistic Regression*. Wiley, 3 edition, 2013.
- [2] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2 edition, 2009.
- [3] Leo Breiman, Jerome H. Friedman, Richard A. Olshen, and Charles J. Stone. *Classification and Regression Trees*. Wadsworth, 1984.

A 支撑材料文件说明

为避免整段程序挤占论文正文篇幅，源代码、清洗数据和程序结果均作为独立支撑材料随论文一并保存：

- 问题二核心程序：`code/q2_optimal_timing.py`;
- 问题二清洗数据：`data/processed/q2_male_cleaned.xlsx`;
- 问题二程序结果：`results/q2/`;
- 问题二正文插图：`figures/q2/`。

正式提交时，应按照比赛当年的支撑材料要求单独提交程序和数据文件，不在论文正文中粘贴完整代码。